

ANN w TensorFlow – klasyfikacja cukrzycy (Pima Indians Diabetes)

Cel

Zbudować i przeanalizować **sieć neuronową w TensorFlow/Keras**, która przewiduje wystąpienie cukrzycy (Outcome) na podstawie cech medycznych.

Nie chodzi tylko o „żeby działało”.

Chodzi o:

- poprawny preprocessing
 - stabilne trenowanie
 - analizę progu decyzyjnego
 - interpretację metryk
-

Dane

Zbiór: **Pima Indians Diabetes**

Kolumna celu:

Outcome (0 – brak cukrzycy, 1 – cukrzyca)

CZĘŚĆ 1 – Eksploracja danych

1. Wczytaj dane do Pandas.
2. Sprawdź:
 - liczbę próbek
 - rozkład klas
 - statystyki opisowe
3. Sprawdź, czy w kolumnach:
 - Glucose
 - BMI
 - Insulin
 - BloodPressure
 - SkinThicknesswystępują zera i czy mogą oznaczać brak pomiaru.

Pytanie:

Czy dane są zbalansowane? Jak to wpłynie na metryki?

CZĘŚĆ 2 – Preprocessing

1. Zamień zera w wybranych kolumnach na NaN.
 2. Uzupełnij brakujące wartości medianą.
 3. Wykonaj standaryzację (StandardScaler).
 4. Podziel dane na:
 - train (80%)
 - test (20%)z użyciem stratify=y. Pytanie:
Dlaczego skalowanie jest ważne dla ANN?
-

CZĘŚĆ 3 – Budowa modelu ANN

Zbuduj model w TensorFlow/Keras:

- warstwa wejściowa
- 2 warstwy ukryte (ReLU)
- warstwa wyjściowa (sigmoid)

Przykładowa architektura:

- Dense(32, activation='relu')
- Dense(16, activation='relu')
- Dense(1, activation='sigmoid')

Skonfiguruj:

- loss: binary_crossentropy
- optimizer: Adam
- metrics: accuracy, AUC

Pytanie:

Dlaczego sigmoid na wyjściu?

CZĘŚĆ 4 – Trening

1. Trenuj model przez 50 epok.
2. Dodaj EarlyStopping (patience=10).
3. Wykreśl:
 - loss treningowy
 - loss walidacyjny

Pytania:

- Czy występuje overfitting?
- W której epoce model przestaje się poprawiać?

CZĘŚĆ 5 – Ocena modelu

Na zbiorze testowym policz:

- Accuracy
- Precision
- Recall
- F1
- ROC-AUC
- Confusion Matrix

Pytanie:

Dlaczego accuracy może być mylące?

CZĘŚĆ 6 – Analiza progu decyzyjnego

Dla progów:

0.2, 0.3, 0.4, 0.5, 0.6

Policz:

- Precision
- Recall
- F1

Zinterpretuj:

- Co się dzieje przy obniżaniu progu?
- Jaki próg byłby sensowny w diagnostyce medycznej?

CZĘŚĆ 7 – Eksperymenty (dla ambitnych)

1. Zwiększ liczbę neuronów.
2. Dodaj Dropout.
3. Zmień learning rate.
4. Porównaj:

- bez BatchNorm
- z BatchNorm

Oceń:

Która konfiguracja daje najlepszy ROC-AUC?

Zadanie rozszerzone (poziom zaawansowany)

1. Porównaj ANN z:
 - Random Forest
 - PCA + SVM
 2. Oceń:
 - czy ANN daje realną przewagę?
 - czy wartość ROC-AUC uzasadnia większą złożoność modelu?
-

Pytania koncepcyjne

1. Co robi funkcja aktywacji?
 2. Czym jest learning rate?
 3. Dlaczego używamy binary crossentropy?
 4. Co oznacza vanishing gradient?
 5. Czy model jest interpretowalny?
-