

Zadanie warsztatowe: Pima Indians Diabetes

Hybrydowy klasyfikator z 3 elementów: PCA + SVM + Random Forest, hyper-tuning i ocena

Cel

Zbudujesz i porównasz modele klasyfikacji ryzyka cukrzycy na zbiorze **Pima Indians Diabetes**. Twoim celem jest zaprojektowanie **złożonego klasyfikatora** (pipeline), przeprowadzenie **strojenia hiperparametrów** oraz wykonanie **rzetelnej oceny jakości** na zbiorze testowym przy użyciu kilku metryk (nie tylko accuracy).

Kontekst danych

Zbiór Pima Indians Diabetes zawiera cechy kliniczne (m.in. glukoza, ciśnienie, BMI, wiek) oraz etykietę binarną:

- **0**: brak cukrzycy
- **1**: cukrzyca (lub podwyższone ryzyko)

W zbiorze mogą występować wartości, które w praktyce klinicznej są nierealne (np. 0 dla BMI, glukozy), co wymaga przemyślanej obróbki.

Wymagania końcowe (co masz oddać)

1. Krótki opis danych i jakości (najważniejsze obserwacje).
 2. Opis przygotowania danych i podziału train/test.
 3. Porównanie **trzech podejść modelowych** (opis poniżej).
 4. Wyniki strojenia hiperparametrów (najlepsze ustawienia + uzasadnienie).
 5. Raport oceny jakości na teście: metryki + macierz pomyłek + interpretacja błędów.
 6. Wniosek: który model/pipeline wybierasz i dlaczego (z perspektywy biznesowo-klinicznej).
-

Część A. Przygotowanie danych (Data Preparation)

Wykonaj następujące kroki:

1. **Wczytaj zbiór Pima Indians Diabetes** i sprawdź:
 - liczbę próbek i cech
 - typy danych
 - rozkład klas (czy jest balans?)
2. **Jakość danych:**
 - Zidentyfikuj cechy, w których „0” może oznaczać brak pomiaru (np. BMI, ciśnienie, glukoza).

- Zaproponuj i zastosuj strategię obsługi takich wartości (np. imputacja, usunięcie wierszy, zamiana na medianę).
- Uzasadnij wybór.

3. Podział na zbiory:

- Wykonaj podział na train/test w sposób, który zachowuje proporcje klas (stratyfikacja).
- Ustal ziarno losowości dla powtarzalności.

Część B. Modele do zbudowania (3 podejścia)

Zbuduj i porównaj trzy konfiguracje:

Model 1: Random Forest (baseline drzewa)

- Trenujesz klasyfikator Random Forest bez PCA.
- Cel: zobaczyć, jak “las” radzi sobie z cechami bez redukcji wymiaru.

Model 2: PCA + SVM (model geometryczny)

- Budujesz pipeline: skalowanie → PCA → SVM.
- Cel: ocenić, czy redukcja wymiaru i separacja w przestrzeni PCA poprawia generalizację.

Model 3: Złożony klasyfikator (ensemble/stacking)

Masz zbudować klasyfikator “złożony” z trzech elementów:

- **PCA + SVM** jako jeden komponent
- **Random Forest** jako drugi komponent
- mechanizm łączenia decyzji (do wyboru przez Ciebie):
 - głosowanie (hard/soft voting), albo
 - stacking z meta-klasyfikatorem

Ważne: w opisie uzasadnij, dlaczego wybrałeś daną metodę łączenia (głosowanie vs stacking).

Część C. Hyper-tuning (strojenie parametrów)

Dla każdego modelu wykonaj strojenie hiperparametrów z użyciem walidacji krzyżowej (CV).

Wymagania:

1. Zdefiniuj **przestrzeń hiperparametrów**:
 - Random Forest: liczba drzew, głębokość, max_features, min_samples_leaf, itp.
 - PCA: liczba komponentów (np. 2–10 / 5–15 / wariant oparty o explained variance)
 - SVM (RBF i/lub linear): C, gamma, kernel

2. Ustal:

- liczbę foldów CV (np. 5)
- metrykę strojenia (niech to nie będzie zawsze accuracy; uzasadnij)

3. Zadbaj o brak “data leakage”:

- wszystkie transformacje uczone z danych (skalowanie, PCA) muszą być uczone tylko na foldzie treningowym w CV, a nie na całości

4. Zapisz:

- najlepsze parametry
- najlepszy wynik CV
- krótką interpretację, co mówią parametry (np. duże C i małe gamma itd.)

Część D. Ocena modelu (Evaluation)

Po wybraniu najlepszego wariantu dla każdego podejścia oceń model na zbiorze testowym.

Wymagane metryki:

- Accuracy
- Precision, Recall, F1-score (przynajmniej dla klasy pozytywnej: “cukrzyca”)
- ROC-AUC (jeśli model daje prawdopodobieństwa)
- Macierz pomyłek + interpretacja: który błąd jest groźniejszy klinicznie (FN vs FP)?

Dodatkowo:

- Krótko opisz, jak zmiana progu decyzji wpływa na Recall/Precision (scenariusz kliniczny: ważniejsze “nie przegapić” niż “nie fałszywie alarmować”).

Część E. Wnioski i rekomendacja

Na końcu odpowiedz na pytania:

1. Który model wygrywa według wybranej metryki i dlaczego?
2. Czy wynik “najlepszy w CV” pokrywa się z wynikiem na teście? Jeśli nie, dlaczego?
3. Jakie są koszty błędów w tym problemie (FP vs FN) i jak to wpływa na wybór modelu?
4. Czy złożony klasyfikator rzeczywiście daje korzyść nad pojedynczym modelem?
5. Jakie dwa ulepszenia w danych lub procesie mogłyby najbardziej poprawić wynik?